Univerzitet u Beogradu

Matematički fakultet

SEMINARSKI RAD

-Istraživanje podataka 2-

Klasterovanje pomoću algoritama mašinskog učenja i istraživanja podataka

Mentor:

Prof. dr Mirjana Maljković Ružičić

Student:

Nikola Krstajić 174/2020

Beograd, mart 2026.

Sadržaj

1 UVOD **1**

1.1 Motivacija **1**

1.2 Ciljevi rada **1**

2 OPIS PODATAKA **1**

2.1 Izvor podataka **1**

2.2 Karakteristike podataka **2**

3 METODOLOGIJA **2**

3.1 Preprocesiranje podataka **2**

3.2 Vizualizacija podataka **3**
3.2.1 2D Vizualizacija 3
3.2.2 3D Vizualizacija 4

3.3 Algoritmi Klasterovanja **4**
3.3.1 KMeans Algoritam 4
3.3.2 BiSecting KMeans 4
3.3.3 Agglomerative Clustering 5
3.3.4 DBSCAN 5
3.3.5 Gausovi modeli mešavine (GMM) 5
3.3.6 Birch Algoritam 6

3.4 Redukcija atributa **6**
3.4.1 PCA 6

3.5 Metrike evaluacije modela **6**
3.5.1 SSE (Sum of Squared Errors) 6
3.5.2 Homogenost 6
3.5.3 Čistoća 6
3.5.4 Sillhouette coefficent (Silueta koeficijent) 7

4 REZULTATI **8**

4.1 Eksplorativna analiza podataka (EDA) **8**
4.1.1 Distribucija klasa (EDA) 8
4.1.2 Box plot sa prosečnom dužinom rečenice 9

4.2 PCA vizualizacija **10**

4.2.1 2D projekcija **10**
4.2.2 3D projekcija 11

4.3 Primena algoritama **12**
4.3.1 KMeans Algoritam 12
4.3.2 Bisecting K-Means 13
4.3.3 Hijerarhijsko klasterovanje (Agglomerative Clustering) 14
4.3.4 Klasterovanje zasnovano na gustini – DBSCAN 16
4.3.5 BIRCH ALGORITAM 16
4.3.6 GMM (Gaussian Mixture Models) 17

5 DISKUSIJA **18**

5.1 Analiza rezultata **18**
5.1.1 Graficko poređenje performansi modela 18
5.1.2 Ocena modela prema Siluet koeficijentu 20
5.1.3 Ocena modela prema ocene homogenosti 20
5.1.4 Ocena modela prema oceni kompletnosti 20

5.2 Finalna ocena modela **21**

5.3 Prakticna primena **21**

5.4 Ograničenja **21**

6 LITERATURA **22**

1 Uvod

U okviru projekta iz predmeta Istraživanje podataka 2, realizovana je analiza i klasterovanje tekstualnih dokumenata (novinskih članaka) iz skupa Reuters podataka.

Cilj ovog rada jeste primena različitih algoritama mašinskog učenja za klasterovanje.

1.1 Motivacija

Potreba za automatskom analizom velike količine tekstualnih podataka bez unapred poznatih oznaka jako je velika. U savremenim problemima u računarstvu, često ne postoji dostupna klasna stuktura, te je neophodno primeniti metode i algoritme nenadgledanog učenja.

Analiza na podacima Reuter_50_50 ispituje da li je stil pisanja autora dovoljan za prirodno grupisanje tekstova primenom algoritama klasterovanja.

1.2 Ciljevi rada

1. Preprocesiranje i priprema tekstualnih podataka za algoritme klasterovanja.
2. Vizuelno predstavljanje podataka u 2D i 3D prostoru.
3. Implementacija i analiza minimum 5 algoritama klasterovanja na datom skupu podataka.
4. Primena različitih tehnika redukcije dimenzionalnosti.
5. Evaluacija kvaliteta korišćenjem internih i eksternih metrika.
6. Identifikacija i analiza najboljeg pristupa klasterovanja.

2 Opis podataka

2.1 Izvor podataka

Skup podataka Reuter_50_50 preuzet je sa UCI Machine Learning Repository-ja, platforme na kojoj se nalazi veliki skup podataka za mašinsko učenje.

- **URL**: https://archive.ics.uci.edu/dataset/217/reuter+50+50
- **Tip problema:** Nenadgledano učenje – Klasterovanje
- **Oblast:** Novinarstvo

2.2 Karakteristike podataka

- U projektu je korišćen skup podataka Reuter_50_50 koji sadrži 50 autora i 50 tekstova za svakog od autora, u trening skupu, i isto toliko u test skupu.

- U radu se nalazi ukupno 5000 dokumenata, na engleskom jeziku. Dataset sadrzi ukupno 50 foldera, po jedan za svakog autora u novinama Reuters. Tekstovi se nalaze u .txt formatu.

- Ovaj skup podataka je balansiran, za svakog autora postoji jednak broj tekstova, dok se razlike nalaze u stilskim, leksičkim i sintaksnim obrascima.

- Prosečan broj reči po dokumentu jeste 505.7, dok tekst sa najmanje reči sadrži 51 reč (autor je Aaron Pressman), dok tekst sa najvećim brojem reči sadrži 1499 reči (autor je Jim Gilchrist).

- Najčešće reči koje se nalaze u ovom Dataset-u, jesu „Percent“, „Million“, „Share“, „Bank“, „China“, „Analysts“, „Business“, „Government“.

- Najčešće reči upućuju na to da ovaj skup podataka sadrži novinske članke koji se bave ekonomijom, politikom, finansijama i tržištem akcija.

- Grafički smo prikazali da se autori razlikuju po prosečnoj dužini rečenice. Postoje autori čija medijana iznosi 13-14 reči, što implicira da oni pišu kratke i jasne vesti, dok postoje autori sa medijanom od 22-23 reči, što ukazuje na kompleksniju i analitičniju analizu.

- Primećujemo da određeni autori (npr. oni sa nižim kutijama) imaju vrlo ujednačen stil pisanja, dok drugi pokazuju veliku varijabilnost u dužini rečenica. Ova razlika u varijansi (visini kutije) je jedna od karakteristika za razlikovanje autora.

- Takođe, izdvojili smo autore koji imaju najbogatiji rečnik (najviše različitih reči koriste).

3 Metodologija

3.1 Preprocesiranje podataka

- Proces preprocesiranja podataka u analizi jedan je od najkritičnijih koraka.

- U fazi preprocesiranja teksta, prvo je izvršena normalizacija teksta prebacivanjem svih reči u mala slova, kako bi se izbeglo dupliranje istih reči zbog različitog zapisa (npr. na početku rečenice). Sledeći korak jeste uklanjanje interpunkcije, čime je rešen

problem redudantnosti, odnosno situacija kada se interpunkcija „lepi “za reč (npr. reči „said“ i „said.” se bez ove tehnike mogu razlikovati).

- Sledeći korak jeste tokenizacija, tj. razbijanje rečenica na pojedinačne reči.
- Nakon toga uklonjene su „Stop-reči“ u engleskom jeziku, kao i termini visoke učestalosti u ekonomskim vestima koje ne doprinose identifikaciji autora. Te reči bi otežavale razlikovanje autora jer se pojavljuju u gotovo svakom tekstu.
- Takođe primenjena je lematizacija korišćenjem „WordNetLemmatizer“, kako bi se različiti gramatički oblici preveli u jedan oblik („running“, „runs“ -> „run“).
- Sledeći korak u pripremi podataka za klasterovanje jeste transformacija u numerički format primenom TF-IDF (Term Frequency – Inverse Document Frequency) matrice.
- Izabrana je ova metoda jer automatski dodeljuje veću težinu rečima koje su u tekstovima disikriminativne, dok manju vrednost dalje rečima koje imaju veću frekvenciju pojavljivanja, tj. one koje su forsirane u novinskim člancima.
- Takođe, TF-IDF matrica balansira reči, tako da ne dominiraju tekstovi koji imaju više reči.
- Ovim korakom, tekstualni podaci transformisani su u visokodimenzionalni vektorski prostor. Ograničili smo broj top reči na 5000, kako ne bismo imali preveliku matricu. Dodatni hiper-parametri koje smo postavili jesu min_df I max_df, tj. da se reč mora pojavljivati u bar 5 dokumenata, i max_df = 0.8, da izbacujemo reči koje se pojavljuju u više od 80% dokumenata.

3.2 Vizualizacija podataka

3.2.1 2D Vizualizacija

Za 2D vizualizaciju korišćena je Principal Component Analysis (PCA) sa 2 komponente. PCA omogućava redukciju dimenzionalnosti sa 5000 komponenata na samo dve, uz zadržavanje najvećeg dela varijanse podataka.

Ova transformacija je ključna jer nam omogućava da posmatramo geometrijsku strukturu stilova autora.

3.2.2 3D Vizualizacija

Za 3D vizualizaciju korišćena je PCA proširenjem na 3 komponente čime je omogućen dodatni uvid u dati skup podataka.

3.3 Algoritmi Klasterovanja

U ovom radu implementirano je 6 različith algoritama mašinskog učenja za klasterovanje.

3.3.1 KMeans Algoritam

Glavni zadatak ovog algoritma jeste da skup podataka podeli u unapred definisan broj grupa (klastera), tako da su podaci unutar iste grupe što sličniji jedni drugima.

Broj klastera postavljamo na 50 (očekujemo taj broj zbog broja autora), a random_state postavljamo na 42.

Ovaj algoritam može da daje lošije rezultate ukoliko se centaroidi biraju sasvim slučajno, te postavljamo n_init na 10, kako bismo proceduru pronalaska centaroida ponovili 10 puta i izabrali najbolju (najmanjom vrednošću SSE).

Parametri :

- n_clusters = 50
- random_state = 42
- n_init = 10

3.3.2 BiSecting KMeans

Bisecting KMeans je varijanta KMeans algoritma koji koristi hijerarhijski pristup pri podeli podataka. Ovo je algoritam razdvajajućeg klastera, koji polazi od jednog velikog klastera koji sadrži ceo skup podataka i deli ga na dva manja sve dok ne postigne zadati broj klastera.

Parametri:

- n_clusters = 50
- random_state = 42
- n_init = 10

3.3.3 Agglomerative Clustering

Agglomerative Clustering jeste algoritam hijerarhijskog klasterovanja, koji pripada grupi sakupljajućeg klasterovanja. Početni stadijum ovog algoritma jeste da svaka tačka predstavlja jedan klaster, i u svakom koraku algoritma se vrši spajanje dva klastera, na osnovu bliskosti. Algoritam se prekida kada se dostigne zadati broj klastera.

Jedna od najbitnijih stvari za efikanost ovog algoritma jeste dobar izbor funkcije bliskosti. Algoritam je urađen sa četiri različite funkcije. Metrika koju koristimo jeste Euklidsko rastojanje.

Parametri:

- n_clusters = 50
- linkage = [„ward“, „single“, „average“, „complete“]
- metric = euclidean

3.3.4 DBSCAN

DBSCAN je algoritam klasterovanja koji je zasnovan na gustini. Osnovna ideja jeste da klasteri predstavljaju regione visoke gustine tačaka koji su razdvojeni regionima koji imaju malu gustinu. U ovom algoritmu ne zadajemo broj klastera, već on sam treba zaključiti na osnovu gustine. Definišemo radijus pretrage kao i minimalni broj uzoraka da bi se nešto definisalo kao klaster.

Parametri:

- eps = 0.6
- min_samples = 5

3.3.5 Gausovi modeli mešavine (GMM)

GMM predstavlja probabilistički model koji pretpostavlja da su svi podaci generisani iz mešavine određenog broja Gausovih raspodela sa nepoznatim parametrima. GMM dodeljuje verovatnoću pripadnosti svakom od klastera.

Broj komponenti određuje broj Gausovih raspodela koji odgovara broju autora.

Covariance type omogućava da svaki klaster ima sopstveni oblik i orijentaciju.

Slično kao i kod KMeans-a, definišemo n_init.

Parametri:

- n_components = 50
- covariance_type = „diag“
- n_init = 10

3.3.6 Birch Algoritam

- Balanced Iterative Reducing and Clustering using Hierarchies (BIRCH)
- Kombinacija hijerarhijskog klasterovanja tipa odozgo nadole i algoritma k – sredina.
- Koristi se hijerarhijska stuktura poznata kao CF-stablo (eng. CF-Tree)

Parametri:

- n_clusters = 50
- threshold = 0.5
- branching_factor = 50

3.4 Redukcija atributa

3.4.1 PCA

PCA zadržava 95% ukupne varijanse koristeći linearnu transformaciju.

3.5 Metrike evaluacije modela

3.5.1 SSE (Sum of Squared Errors)

Suma kvadratnih grešaka - interna metrika koja meri ukupnu varijansu unutar klastera.

Matematički se definiše kao suma kvadrata rastojanja svake tačke x od njenog pripadajućeg centaroida.

3.5.2 Homogenost

Eksterna metrika koja ispituje u kojoj meri svaki klaster sadrži samo podatke koji pripadaju jednoj klasi (jednom autoru). Vrednost rezultata jeste između 0 i 1.

3.5.3 Čistoća

Mera tačnosti koja se izračunava tako što se za svaki klaster odredi dominantna klasa (autor koji ima najviše tekstova u tom klasteru), zatim se sumira broj dokumenata koji su ispravni i podeli sa ukupnim brojem dokumenata N.

3.5.4 Sillhouette coefficent (Silueta koeficijent)

Mera kvaliteta koja određuje koliko su instance grupisane sa instancama koje su slične njima samima.

Prvo se silueta koeficijent računa za svaku instancu po formuli:

$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

gde je

- a(i) – prosečno rastojanje između instance i ostalih instanci u istom klasteru
- b(i)– najmanje prosecno izmedju instance i i instanci iz najblizih susednih klastera

Silueta koeficijent za ceo skup je prosečna vrednost koeficijenta za pojedinačne instance.

Vrednost silueta koeficijenta je između [-1,1], pri čemu je :

- -1 za neispravno grupisanje
- +1 za gusto grupisanje
- Vrednost oko nule ukazuje na to da instance nalazi izmedju dva klastera

Vrednost koeficijenta je veca kada su klasteri gusti i dobro razdvojeni.

4 Rezultati

4.1 Eksplorativna analiza podataka (EDA)

4.1.1 Distribucija klasa (EDA)

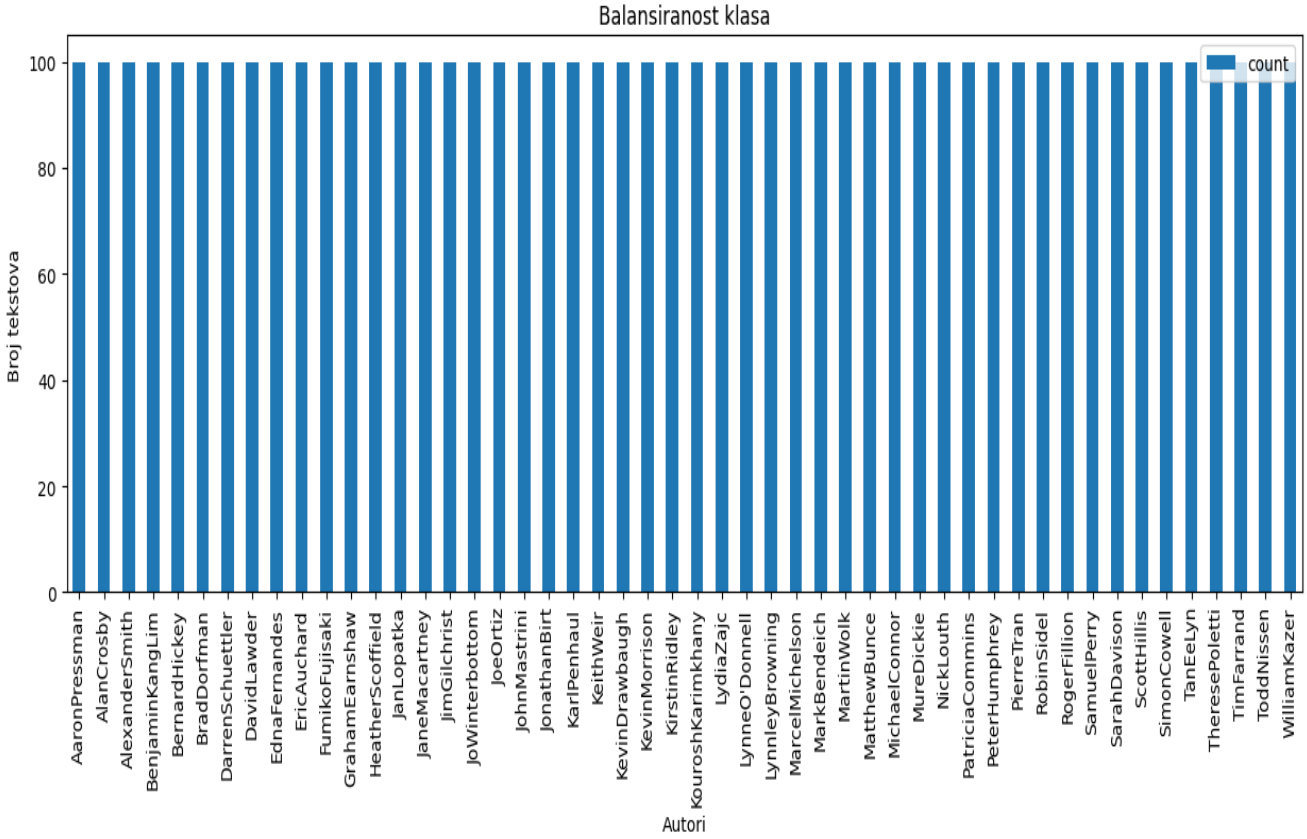

Slika 1. Distribucija klasa u Reuter50 1

Eksplorativna analiza pokazuje da su klase balansirane, za svakog autora postoji jedan broj tekstova. Nije potrebno odraditi nikakvo balansiranje klasa.

4.1.2 Box plot sa prosečnom dužinom rečenice

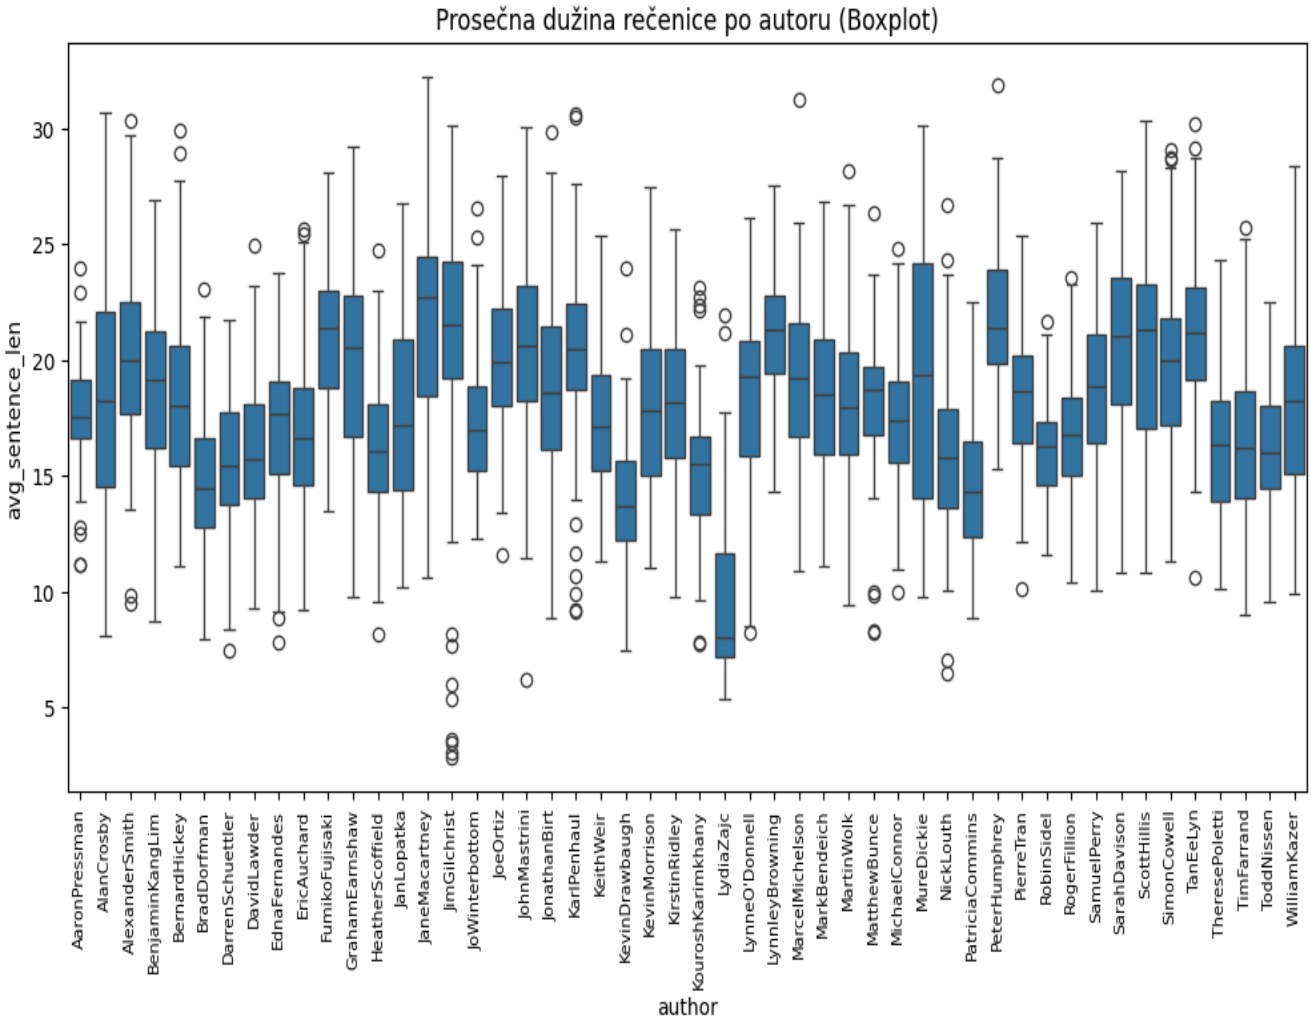

Slika 2. Boxplot za dužinu rečenice

Boxplot nam pokazuje koliko će dužina rečenice moći da nam pomogne prilikom identifikacije autora.

4.2 PCA vizualizacija

4.2.1 2D projekcija

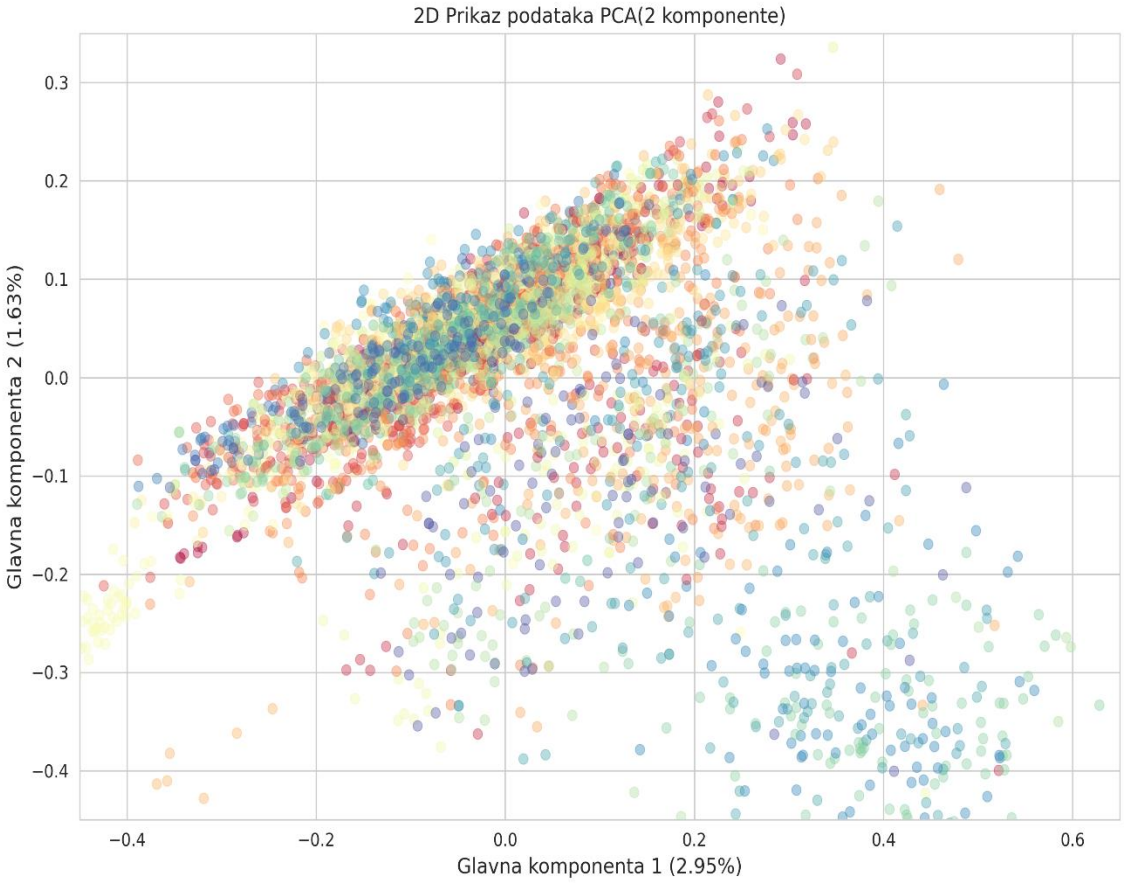

Slika 3: PCA 2D prikaz

- Na slici prikazana je projekcija matrice na dve glavne komponente. Svaka tačka predstavlja jedan tekst, dok različite boje predstavljaju različite autore.
- Iako prve dve komponente objašnjavaju 4.58% ukupne varijanse, ovo je rezultat koji je očekivan za tekstualne podatke i za novinske članke. Svaki autor koristi specifičan podskup reči koji se ne mogu svesti na samo par globalnih tema.

4.2.2 3D projekcija

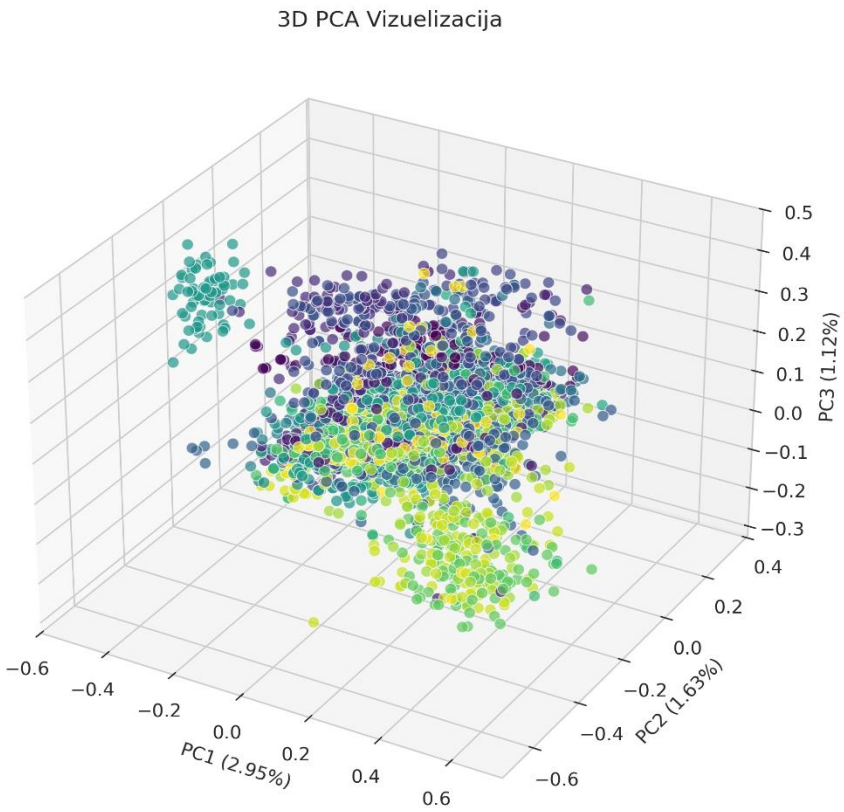

Slika 4. 3D PCA prikaz

- 3D vizuealizacija predstavlja dodatni uvid u našu strukturu podataka

4.3 Primena algoritama

4.3.1 KMeans Algoritam

Kao prvi algoritam koristimo KMeans algoritam sa celim skupom atributa kao i sa redukovanim skupom atributa.

U oba slučaja, broj klastera postavljamo na 50 (toliko imamo i različitih autora).

Poređenje KMeans performansi: Full Features vs PCA

Metrika	Bez PCA (Full)	Sa PCA (95% var)
Silhouette Score	0.068	0.075
Homogenost	0.542	0.526
Kompletnost	0.584	0.584
SSE (Inertia)	3.973	3.722

Slika 5. Rezultati KMeans algoritma

Ukoliko uporedimo rezultate Silhouette Score-a, pre i posle redukcije, videćemo da postoji rast koeficijenta sa 0.068 na 0.075. Iako su ove vrednosti niske (tekstovi su slični jer su iz istih kategorija, vokabular je sličan), ovaj rast predstavlja pozitivan trend. On ukazuje na to da je PCA uspešno eliminisao šum, čime su centri klastera jasnije definisani nego na celom skupu atributa.

Homogenost je na zadovoljavajućem nivou od 0.54 u slučaju sa celim skupom, čime algoritam teži da formira klastere sa visokom čistoćom, gde većina dokumenata unutar jednog klastera pripada istom autoru.

Model uspešno pronalazi specifične stilske obrasce koji su jedinstveni za autore. Minimalni pad homogenost na 0.52 kod PCA, dokazuje da hibridni model ne gubi ključne informacije, čak i kada smanjimo broj atributa.

Kompletnost je u oba slučaja na vrednosti od 0.585. To implicira da algoritam uspešno okuplja tekstove jednog autora na jedno mesto(unutar jednog klastera). Manja je verovatnoća da će tekstovi biti rasuti u veliki broj klastera.

4.3.2 Bisecting K-Means

Sledeći algoritam koji koristimo jeste Bisecting K-Means.

Algoritam je primenjen na celom skupu podataka kao i na redukovanim PCA podacima koji sadrže 95% varijanse.

Dobijeni su sledeći rezultati:

Uporedni rezultati Bisecting K-Means algoritma

Model i Skup podataka	SSE (Inertia)	Silhouette Score	Homogenost	Kompletnost
Bisecting KMeans (Full)	4193.49	0.032	0.509	0.535
Bisecting KMeans (PCA)	3920.27	0.047	0.496	0.537

Slika 6 Rezultati Bisecting KMeansa

- U datim rezultatima može se primetiti porast Sileuet koeficijenta nakon primene PCA. Ovo ukazuje na to da su klasteri u smanjenom prostoru postali kompaktniji i bolje razdvojeni. Redukcija dimenzionalnosti se pokazala kao dobra i uklonila je deo šuma.
- Homogenost na punom skupu podataka nešto je viša nego na PCA verziji. Postignuta homogenost od 0.509 ukazuje na to da algoritam uspešno identifikuje jezgro stilskih karakteristika autora. TF-IDF vektori dovoljno su precizni da razdvoje autore. Činjenica da klasteri nisu mešoviti, potvrđuje postojanje stilskog otiska kod svakog od autora, koji biva bitniji od teme kojom pišu. I u situacijama gde autori pišu o jako sličnim temama, stil uspeva da dođe do izražaja.
- Pad homogenosti u PCA verziji može se tumačiti tako da Bisecting K-Means koristi sitne varijanse u podacima, kako bi doneo odluku o klasterima. Kada se smanji dimenzija podataka, te varijanse mogu nestati.
- Kompletnost ima veću vrednost od homogenosti, algoritam je uspešan u prepoznavanju konzistentnosti autorskog stila. Algoritam je skloniji da opus jednog autora drži u jednom većem klasteru, nego da ga framgentira na više grupa.

4.3.3 Hijerarhijsko klasterovanje (Agglomerative Clustering)

Nakon Bisection K-Means algoritma primenjeno je Agglomerativno hijerarhijsko klasterovanje.

FINALNI REZULTATI: WARD CLUSTERING

Metrika	Full (Original)	PCA (95% var)	Razlika
Silhouette Score	0.065	0.069	0.004
Homogenost	0.515	0.514	-0.001
Kompletnost	0.582	0.583	0.001

Slika 7: Rezultati Agglomerative Clustering-a sa Ward linkage-om

- Za prikaz rezultata izabrana je Ward metoda, jer dalje najbolje rezultate, u oba slučaja. Single Linkage daje ubedljivo najgore rezultate. Očekivano su bolji rezultati u Ward metodi nego u Single metodi, zbog tendecije Ward metode da formira klastere sličnih veličina I minmalne unutrašnje varijanse, što odgovara strukturi gde su nam sve klase balansirane.
- Nakon primene PCA primećuje se blagi porast Siluet koeficijenta. Iako je razlika mala, ona ukazuje da je redukcija dimenzionalnosti uspešno eliminisala sum iz TF-IDF matrice, čime su granice između klastera postale jos jasnije.
- Homogenost je gotovo identična, što znači da PCA model u potpunosti čuva informaciju o stilu pisanja autora.
- Na osnovu dobijenih rezultata može se zaključiti da je Ward metoda izuzetno robusna za ovaj problem.
- Ključno saznanje jeste da redukcija ne narušava integriret podataka. Time se opravdava korišćenje PCA tehnike radi uštede računarskih resursa i vremena, bez žrtvovanja preciznosti.

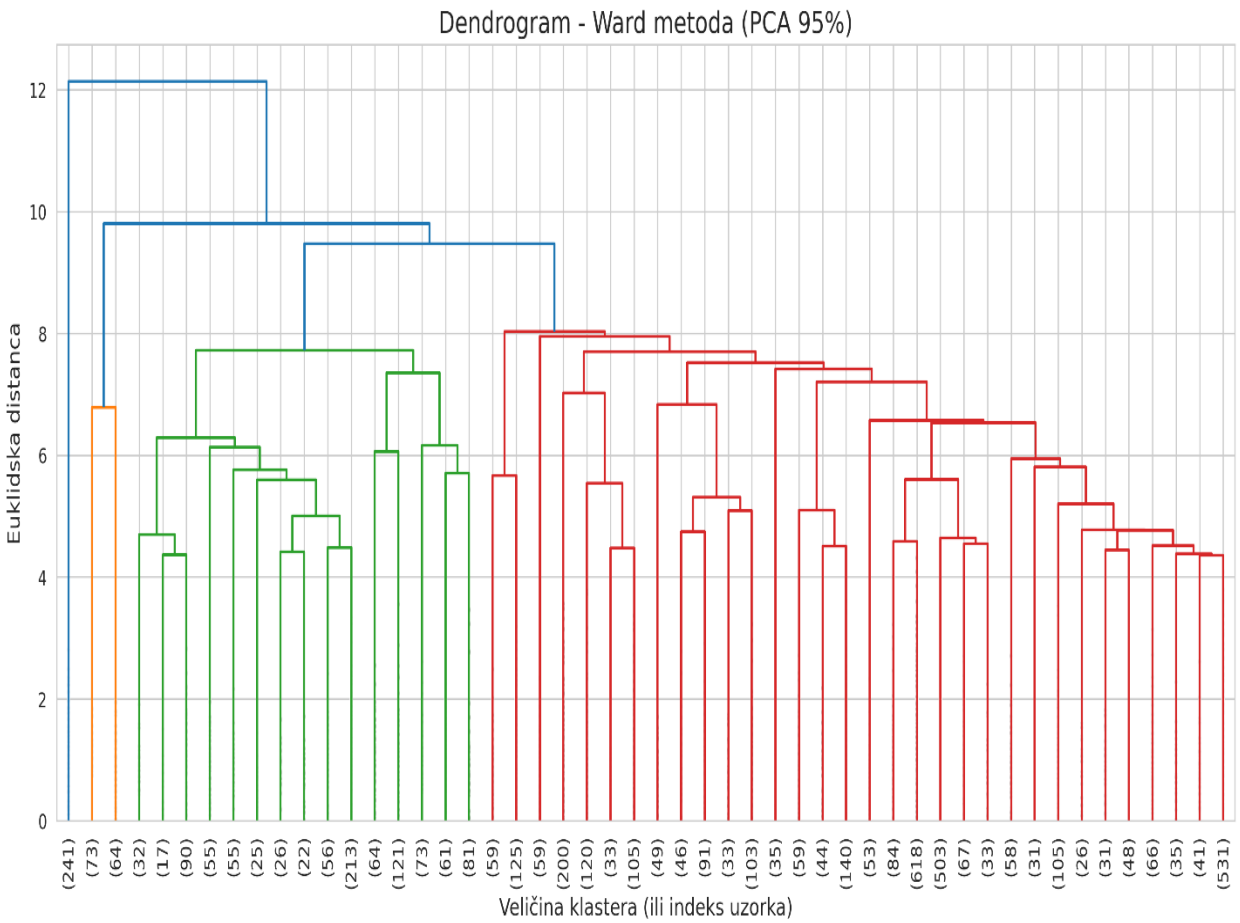

Slika 8. Dendogram - Grafički prikaz

- Dendogram pokazuje kako se stilovi autora grupišu u veće celine pre nego sto se konačno spoje u jedan zajednički skup.

4.3.4 Klasterovanje zasnovano na gustini – DBSCAN

Sledeći u nizu algoritama jeste DBSCAN

Rezultati su sledeći:

DBSCAN Rezultati: Full vs PCA (eps=0.6, min_samples=5)

Podaci	Nađeno klastera	Šum (Noise)	Siluete	Homogenost	Kompletnost
Pun skup (Full)	16	4881	-0.032	0.023	0.515
PCA (95%)	48	4624	-0.044	0.071	0.512

Slika 9: Rezultati DBSCAN modela

- Dobijeni rezultati DBSCAN algoritmom drastično se razlikuju od hijerarhijskih i particinonih modela. Glavna karakteristika ovih rezultata jeste ekstremno visok procenat podataka koji je označen kao sum.
- Ovaj model je pokazao da naši podaci ne formiraju uniformno guste klastere, već se sastoje od manjih jezgara koji su okruženi velikim brojem atipičnih uzoraka.
- Rezultati na PCA podacima (48 klastera, blizu ciljnih 50), ukazuju da je ovo neophodan preduslov za algoritme koji se zasnivaju na gustini.

4.3.5 BIRCH ALGORITAM

Uporedni prikaz BIRCH rezultata (Full vs PCA)

Verzija Modela	Silhouette Score	Homogenost	Kompletnost
BIRCH (Pun skup)	0.054	0.511	0.573
BIRCH (PCA 95%)	0.051	0.533	0.579

Slika 10: Rezultati BIRCH modela

- Birch algoritam se izdvojio kao efikasan model u ovom istraživanju pogotovo sa PCA redukcijom. Postignuta kompletnost od 0.579 i homogenost od 0.533, predstavljaju visoke vrednosti u poredjenju sa dosadašnjim rezultatima.
- Ovi rezultati potvrđuju da hijerarhijsko sažimanje karakteristika, najbolje odgovara prirodi naših podataka. Ovaj algoritam uspeva da integriše atipične uzorke u ispravne grupe, čime smanjuje gubitak informacija i pogrešno klasterovanje. Pozitivan rezultat sledi iz specifične structure CF – stabala.
- Za razliku od DBSCAN – a, koji je šum potpuno izolovao, BIRCH je uspeo da granične slučajeve pravilno alocira, što je dovelo do rasta metrike homogenosti i kompletnosti istovremeno. BIRCH je uspeo da izbalansira ove dve vrednosti.

4.3.6 GMM (Gaussian Mixture Models)

Dobijeni su sledeći rezultati primenom ovog algoritma:

GMM (Gaussian Mixture Model) Rezultati

Verzija Modela	Silhouette Score	Homogenost	Kompletnost
GMM (Pun skup)	0.062	0.530	0.573
GMM (PCA 95%)	0.039	0.388	0.439

Slika 11: Rezultati dobijeni GMM

- GMM je pokazao izuzetnu preciznost na originalnom skupu podataka, postižući homogenost od 0.530. Ovi rezultati ukazuju na to da se stil autora može matematički modelovati preko statističke distribucije.
- Ovaj model se pokazao jako osetljiv na promenu dimenzionalnosti atributa. GMM beleži značajan pad svih metrika kada smanjimo dimenziju.
- Ovo ukazuje na to da za efikasnu primenu GMM algoritma na tekstualnim podacima, treba raditi sa originalnim podacima.

5 Diskusija

5.1 Analiza rezultata

5.1.1 Graficko poređenje performansi modela

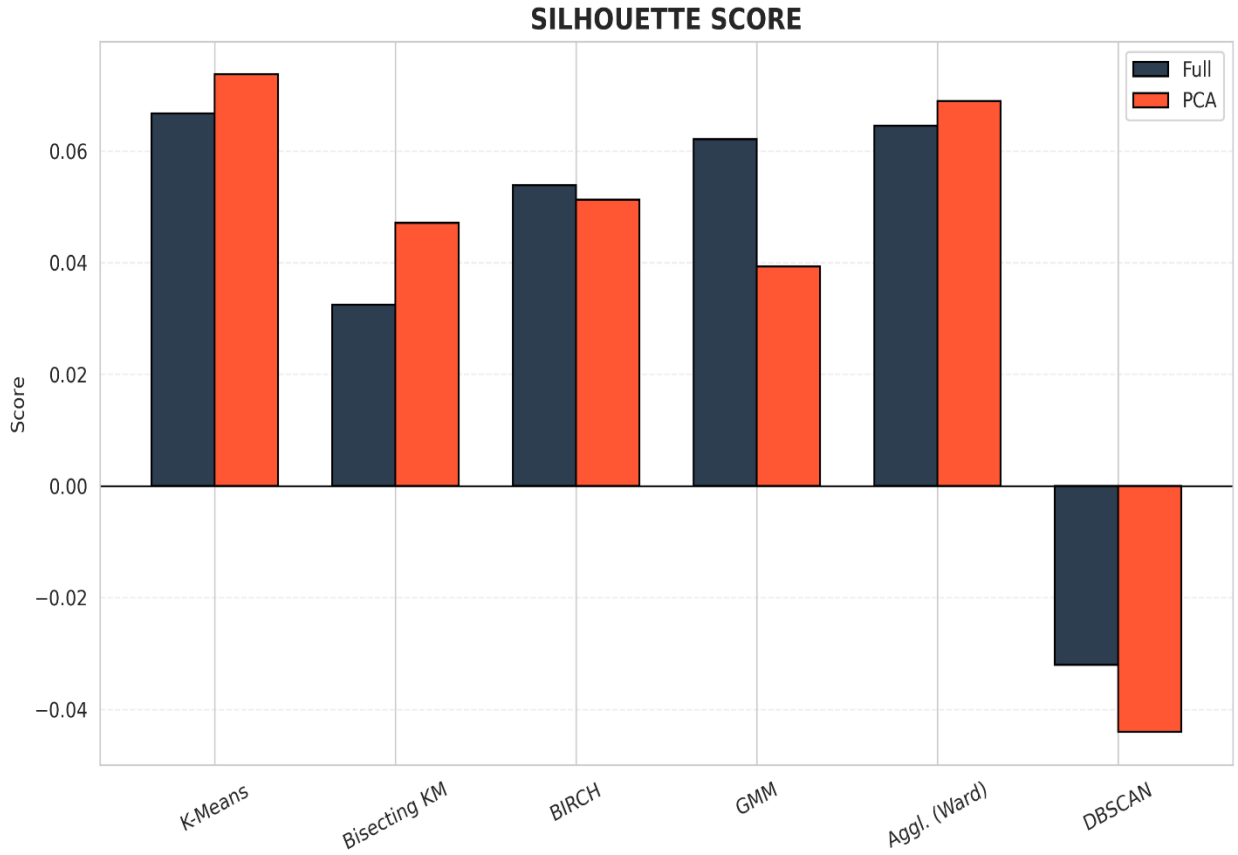

Slika 12. Prikaz Siluet koeficijenta kroz modele

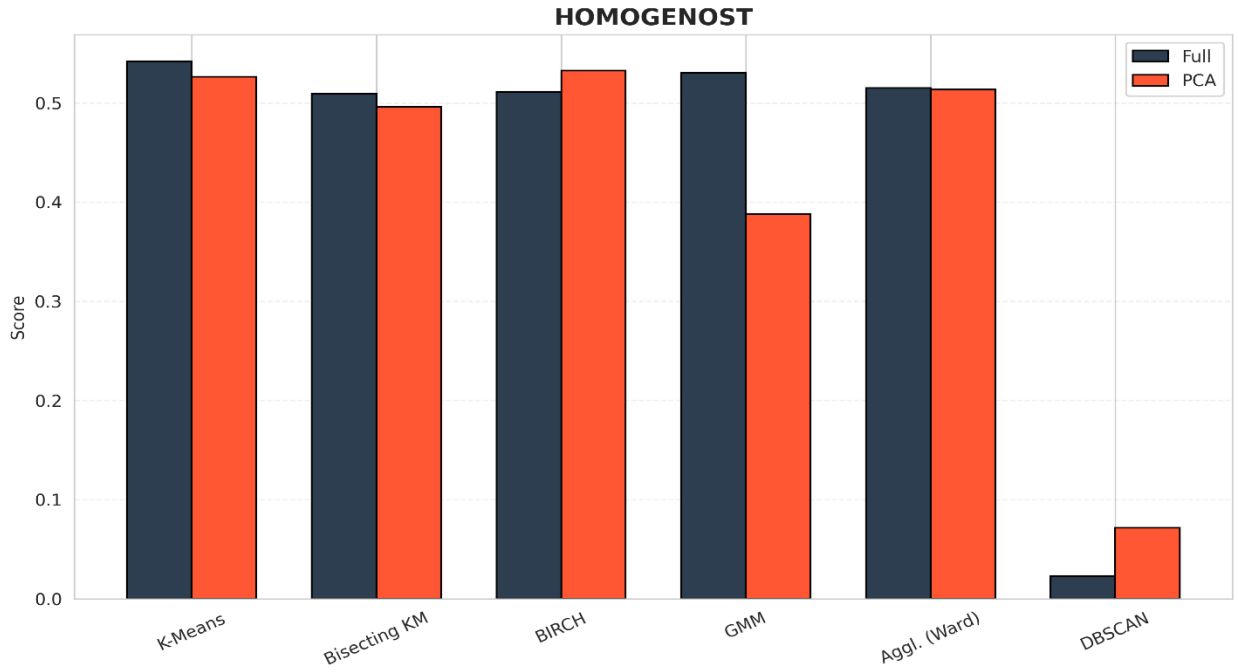

Slika 13. Prikaz Homogenosti kroz modele

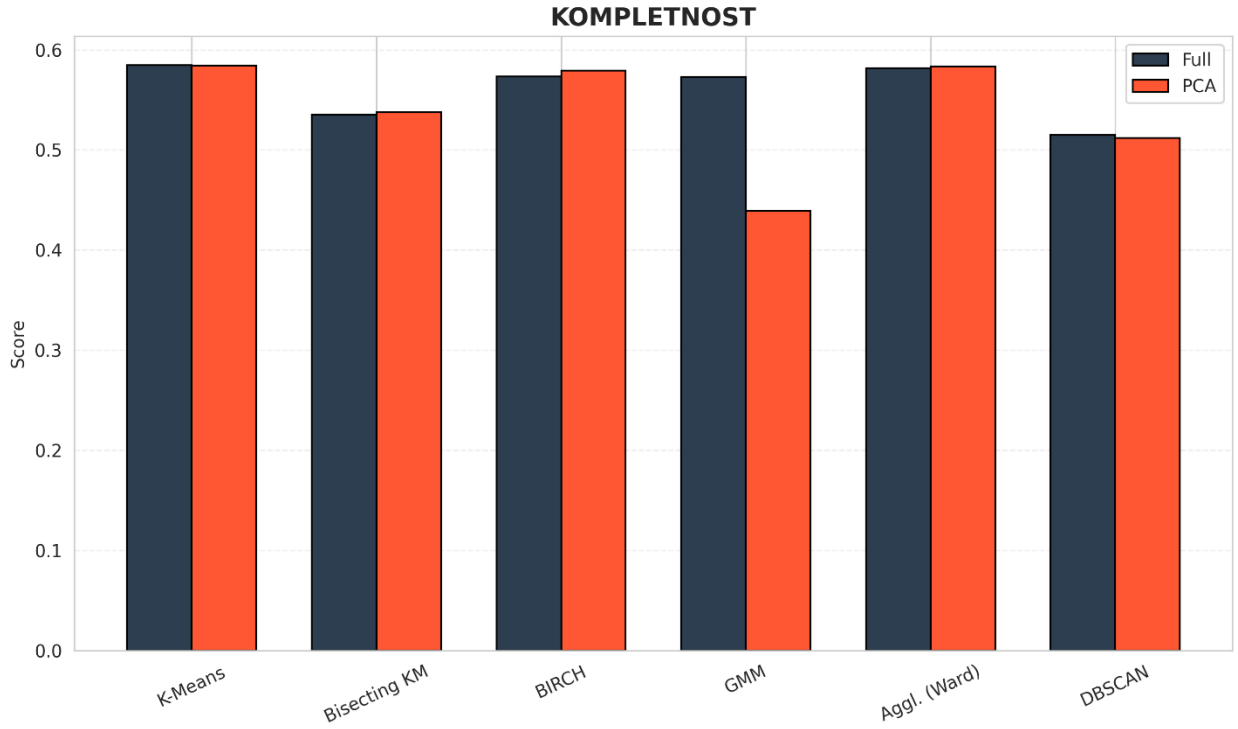

Slika 14. Prikaz Kompletnosti kroz modele

5.1.2 Ocena modela prema Siluet koeficijentu

- Niska apsolutna vrednost Siluet koeficijenta direktna je posledica gustine stilometrijskog prostora u kojem različiti autori dele značajan deo vokabulara, pošto je tematika svim autorima slična.
- Modeli K-Means i Agglomerative (Ward) ostvaruju najbolje rezultate.
- Uticaj PCA na svaki od modela je jako pozitivan, kod velike većine modela viši je od modela sa celim skupom podataka. Ovo je dokaz da je smanjenje dimenzionalnosti pomoglo modelima da jasnije vide razlike, jer su izbačeni manje bitni podaci.
- Najgore rezultate dao je model DBSCAN, on ima negativnu vrednost. Ovo ukazuje na to da ovaj model nije pogodan za visoko-dimenzionalne tekstualne podatke jer ne uspeva da pronađe regione niske gustine među onima koji imaju veliku gustinu.

5.1.3 Ocena modela prema ocene homogenosti

- Na grafiku vidimo da K-Means i Agglomerative (Ward) opet ostvaruju najbolje rezultate. Njihova homogenost prelazi 0.50. S obzirom da postoji 50 različitih autora, ovaj rezultat može se uzeti kao uspeh, jer potvrđuje da stil moze dominirati nad opštim sličnostima u jeziku.
- Grafik homogenosti pokazuje da je Ward metoda najrobusnija. Gotovo da ne postoji razlika između čitavih podataka i PCA modela, što ukazuje da PCA skoro savršeno čuva pečat autora.
- Može se primetiti takođe, da GMM pokazuje drastičan pad, nakon redukcije dimenzionalnosti, što daje zaključak da GMM zahteva punu dimenzionalnost za optimalnije rezultate.
- DBSCAN još jednom pokazuje veliki neuspeh. Ostvaruje homogenost blizu nule. Ovo jasno pokazuje da algoritmi zasnovani na gustini teško identifikuju autore u jako gustom i preklapajućem prostoru.

5.1.4 Ocena modela prema oceni kompletnosti

- Na grafiku se jasno vidi Agglomerative i K-Means opet postižu najviše vrednosti, koje se približavaju cifri od 0.60. Ovo je visok rezultat za stilometriju, jer potvrđuje da stilski potpis jednog autora nije rasut, vec je dovoljno konzistentan da ga većina algoritama prepozna kao jedinstvenu celinu.

- Grafik pokazuje da se BIRCH pokazuje kao ozbiljan kandidat sa ocenom kompletnosti koja je jako blizu vodećih modela. Ovo ukazuje na to, da iako ovaj model baziran na drugačijoj hijerarhijskoj logici, jeste podjednako sposoban da obuhvati celokupne tekstove jednog autora.
- Kao i kod homogenosti, GMM beleži drastičan pad nakon PCA transformacije, što jos jednom pokazuje njegovu slabost kada dođe do smanjenja dimenzionalnosti.
- DBSCAN je postigao visoku vrednost kompletnosti, ali s ovime treba biti oprezan, jer postoji mogućnost, da je takvu ocenu dostigao tako što je ogroman broj dokumenata spojio u jedan veliki „megaklastera“, što je u praksi neupotrebljivo.

5.2 Finalna ocena modela

- Nakon rigoroznog testiranja 6 različitih algoritama, može se doneti zaključak da najoptimalnije rezultate daje **Agglomerative Clustering sa Ward Linkage-om**.
- Dok su drugi modeli bili osetljivi na promenu dimenzije podataka, ovaj model ostao je netaknut. Minimalna razlika u homogenosti dokazuje da ovaj model autore ne pogađa slučajno, vec se drži stilskih zakonitosti.
- BIRCH model može da parira Ward-u u homogenosti i kompletnosti ali ne može da parira u vrednosti Siluet koeficijenta.
- Ovaj model daje dobre rezultate u sve tri ključne kategorije: homogenosti, siluet koeficijentu i kompletnosti.
- Takođe, Ward nam može dati Dendogram, grafički prikaz rezultata, koji ga svrstava ispred K- Meansa.

5.3 Prakticna primena

- **Filtriranje AI generisanog sadržaja –** Sličan pristup ovom istraživanju može se primeniti za razlikovanje ljudskog stila od stila veštačke inteligencije.
- **Cyber Forenzika** – Model moze identifikovati različite korisničke naloge na forumima i društvenim mrežama, prema stilu pisanja, koji pripadaju istoj osobi.

5.4 Ograničenja

- **Zavisnost od dužine teksta –** Ukoliko su tekstovi prekratki, statistička distribucija postaje nestabilna.
  Model bi imao dosta nižu homogenost na tekstovima sa društvenih mreža u poređenju sa esejima i knjigama.
- Nekada je teško razdvojiti stilove autora ukoliko pišu o jako sličnim temama.

- Model pretpostavlja fiksni broj autora, što u neregulisanim uslovima može stvarati probleme.

6 Literatura

[1]. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830

[2]. Harris, C. R. et al. (2020). Array programming with NumPy. Nature, 585(7825), 357-362

[3]. McKinney, W. (2010). Data structures for statistical computing in python. In Proceedings of the 9th Python in Science Conference

[4]. T. Zhang, R. Ramakrishnan, and M. Livny, "BIRCH: An efficient data clustering method for very large databases" ACM SIGMOD Record

[5]. Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD), 96(34), 226-231.

[6]. Tipping, M. E., & Bishop, C. M. (1999). Mixtures of probabilistic principal component analyzers. Neural Computation, 11(2), 443-482.

[7]. Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information processing & management, 24(5), 513-523

[8]. https://scikit-learn.org/stable/modules/clustering.html#clustering-performance-evaluation

[9]. https://scikit-learn.org/stable/modules/clustering.html#